

AnatoBind-MRI

完整技术方案与研发闭环

Anatomy-Abnormality Binding with Relation Reliability under MRI Degradation

核心研究问题 当 MRI 采集退化使 segmentation / detection 的预测几何变得不可靠时，模型能否仍然正确建立“异常属于哪个解剖结构”的关系，并同时知道这条关系何时已经不值得相信？

项目主线



版本基准：GitHub main / 2026-09-09 最新状态；研究方案 v2.1 + 09-09 expert audit 的方法学修正。

定位：3D MRI 结构化感知与关系学习框架，不称 foundation model。

这份文档不是“模块说明书”。它按科学问题 → 方法假设 → 数据与监督 → 模型 → 干预 → 训练 → 推理 → 实验验证 → 失败判据 → 开发路线的顺序，形成一条可执行的技术闭环。

阅读地图：先看逻辑，再看模块

一句话 AnatoBind-MRI 不只是“找病灶”，而是把 MRI 中的解剖实体和异常事件显式组织成关系，并在真实可控的 MRI 退化下学习“什么时候仍能相信这条关系”。

章节	回答的问题
1. 科学问题与假设	为什么传统 segmentation / detection 不足？研究真正要证明什么？
2. 问题形式化	A、S、U_B、U_Q、R、E 分别代表什么，彼此如何依赖？
3. 数据与监督	哪些数据提供 anatomy / lesion / relation / raw k-space / degradation truth？
4. 模型主干	输入如何保留物理空间，3D Swin 如何产生多尺度特征？
5. 结构化语义	如何从 feature 产生 anatomy entity 与 abnormality event？
6. 关系建模	如何构造每个异常-解剖 pair，并显式预测 main host？
7. 关系可靠性 E	为什么置信度不等于可观测性？如何监督 E？
8. k-space 干预	如何保持生物真值不变，只改变“证据质量”？
9. 训练与损失	四阶段为什么按依赖顺序训练？每个 loss 在解决什么？
10. 推理闭环	一张新 MRI 进来后，最终输出是什么？
11. 实验与证伪	怎样和公平 baseline 比，怎样证明不是“加参数”？
12. 当前实现与路线	代码已经做到哪里，下一步怎样最短路径验证核心假设？


最重要的方法学更新（2026-09-09） 公平的 class-aware seg-then-lookup oracle 在干净 SKM-TEA 上组织族级 ABA 已达 0.968，因此“clean binding 比查表高 10 个百分点”不是合理主目标。真正非平凡的主线应转向：退化导致预测 geometry 失效后的 relation robustness，以及 relation-level reliability E。

Figure 1. AnatoBind-MRI 全局技术架构

先用这张图建立全局直觉，后面的章节再沿数据流逐段推导。

AnatoBind-MRI: Anatomy–Abnormality Binding with Relation Reliability

A structured 3D MRI perception framework for anatomically grounded abnormality understanding



实线 = 当前核心已实现；虚线/Planned = 完整方案。当前可执行路径主要为 $X \rightarrow \text{Swin} \rightarrow \{\mathcal{A}, U_B\} \rightarrow G \rightarrow \text{Relation Transformer} \rightarrow R$ ； S 、 U_Q 、局部 ROI、 E 与完整 paired intervention training 仍待实现。

1. 科学问题：为什么“识别病灶”还不够？

传统 MRI AI 往往把任务拆成 segmentation、detection、classification：模型能分别找到解剖结构和病灶，但这并不自动保证模型形成稳定的“WHAT IS WHERE”关系表示。临床推理真正关心的是：这个异常属于哪个解剖结构、是否跨多个结构、当前图像是否还有足够证据支撑这种归属。

1.1 基础区分：识别 ≠ 绑定



例如，一处 meniscal tear 的 detector 可以给出很高的“tear”概率，anatomy segmentation 也能分别得到 medial / lateral meniscus；但 severe undersampling 或 motion 使 lesion box 偏移后，单纯 IoA lookup 可能把病灶绑错。此时“病灶还存在”和“宿主关系仍可可靠判断”是两个不同问题。

1.2 核心科学假设

H1 - Binding robustness 在预测 geometry 受退化扰动的条件下，显式 pair-level relation representation 能比 class-aware seg-then-lookup / pair MLP 更稳健地恢复 abnormality → anatomy 的主宿主关系。

H2 - Relation reliability 模型可以学习一个关系级 E_{ij} ，使它不仅输出“我认为 U_j 属于 A_i ”，还输出“当前图像是否足以支撑这个判断”； E 应能预测关系失效并优于 softmax/entropy/IQA/learned failure baselines。

H3 - Intervention generalization 同一病例的 raw k-space 可生成对的干净/退化视图；如果模型学到的是生物关系而不是图像质量捷径，高证据时 R 应保持， U_Q 应响应退化， E 应随证据下降，并能迁移到真实或未见退化。

1.3 研究故事的修正

最新审计发现：公平的 class-aware lookup（按病灶类别限制候选结构 + IoA + 零重叠最近结构兜底）在 309 个宿主已知实例上组织族级准确率 0.968。半月板撕裂达到 1.000，软骨病变 0.952。因此 clean data 上 relation Transformer 的可争空间只有约 3 个百分点。项目不应该再押注“干净数据显著击败查表”，而应该把查表视为强 baseline，并把主实验移到 prediction failure under degradation。

2. 问题形式化：从 MRI 图像到结构化关系图

输入是一张任意尺寸 3D MRI 体数据 X。模型不把它压缩成一个单一分类向量，而是先构造实体与事件，再构造它们之间的关系，并为每条关系预测可观测性。

```
X -> {F1, F2, F3, F4} -> (A, S, U_B, U_Q)
(A, S, U_B, geometry) -> pair token r_ij -> R_B
(r_ij, local image evidence) -> E_ij
```

变量	语义	输出粒度	是否进入关系 R
A = {A_i}	解剖实体：身份、mask、presence、embedding	每个解剖结构	是
S	采集条件：序列、场强、方向、脂抑等	整卷全局	完整方案中作为条件
U_B = {U_j}	生物异常事件：类型、3D box、embedding	每个异常实例	是
U_Q	采集诱发全局退化：motion/noise/aliasing presence+severity	整卷全局	不产生 R_Q
R_ij	异常 U_j 与解剖 A_i 的软关系 + main host	每个候选 pair / event	核心输出
E_ij	当前图像是否足以支持对 U_j→A_i 的关系判断	每个候选 pair	可靠性输出

2.1 生成模型视角

```
X = R_S( A ⊗ U_B ; U_Q )

U_B: acquisition 之前已经存在，天然依附 anatomy
U_Q: acquisition/reconstruction 过程中产生，可同时影响多个结构
```

这个不对称性决定了模型设计：U_B 是带位置的 instance query；U_Q 是全局多标签 degradation branch。把 motion/noise 也当成 lesion query 会混淆 biology 与 acquisition。

2.2 none / no-object / unknown / low-E 必须分开

状态	含义	正确处理
no-object	某个 anatomy/event query 实际为空	不参与有效 pair；检测/存在性任务处理
none host	事件真实存在，但确实无宿主（如积液）	main-host softmax 的 none 类
unknown host	标注不足或侧别无法解析	relation loss 中 ignore，不当负类
low E	事件和关系真值没有改变，但当前图像证据不足	降低/关闭确定性关系监督，不能改成 none

3. 数据与监督闭环：每一种变量从哪里得到真值？

AnatoBind 的设计不是先堆网络再找标签，而是把每个输出变量绑定到可审计的数据来源。主战场 SKM-TEA 的特殊价值在于：同一次扫描同时具备 raw k-space、重建、6 类解剖分割、3D 病灶框和标注者 tissue_id，因此能够同时支持 anatomy、event、relation 和 physical intervention。

数据源	主要规模/特征	在方案中的角色
SKM-TEA	155 scans; qDESS raw k-space + ESPIRiT maps + 6 tissue masks + lesion boxes/tissue_id	M1 主战场; A、U_B、R*、k-space intervention
fastMRI brain/knee	脑约 4469 train + 1378 val; 膝 973 + 199; 多序列、多场强 raw	SSL、S、跨协议干预
fastMRI+	脑/膝 lesion boxes; 部分真实 artifact labels	U_B 辅助监督; 真实 artifact 测试
PDGM/BMSR/ISLES	脑肿瘤/转移瘤/卒中 mask	第二战场 U_B; 结合 SynthSeg anatomy
SynthSeg pseudo-labels	脑解剖伪标签管线已完成多库	脑侧 A; 需披露伪标签误差
KMAR-50K	真实膝 motion artifact / GT 配对	sim-to-real 只测试, 不进训练

3.1 SKM-TEA relation truth

主宿主真值优先来自标注者 tissue_id，而不是由 overlap 反推。原因非常直接：如果 relation target 本身由 IoA 定义，那么 seg-then-lookup 在定义层面已经拿到了答案，relation model 不可能证明额外价值。侧别需要额外几何规则解析，因此主统计应使用组织族级 ABA。

```
R* <- annotator tissue_id (NOT argmax IoA)
```

3.2 数据处理状态

- SKM-TEA M1 导出 155/155 完成：clean、noise q1/q2/q3、undersampling ×4/×8/×16、seg、boxes、manifest、5-fold split。
- 脑侧 SynthSeg-robust 伪标签已经完成多个数据集；但当前训练主路径尚未把脑侧与膝侧统一到一个 model ontology。
- 当前 Arm-B dataset 只读取 SKM-TEA 第一回波 clean crop；因此“完整多器官、多退化训练”仍是目标方案，不是现有代码事实。

4. 输入表示与 3D Backbone：保留 MRI 的物理空间

设计目标不是把所有 MRI resize 成 128^3 ，而是在尽量保留真实 anatomy geometry 的前提下处理不同 $D \times H \times W$ 和 anisotropic spacing。固定 resize 会同时改变病灶尺寸、器官比例和 artifact 空间模式，反而削弱 relation learning。

4.1 预处理



- 当前可执行 Arm-B: $64 \times 128 \times 128$ lesion-centered crop, 0.5/99.5 percentile clip + z-score。
- 完整方案：仅在极端 spacing 做温和 resample；pad 只为 patch/window 整除，同时生成 M_valid ，推理采用 sliding window。
- 物理坐标：每个 token 保留 $(x,y,z)_mm$ 与局部归一化坐标，避免“同样 4 voxels”在不同 spacing 下代表不同距离。

4.2 3D Swin hierarchy

层级	完整目标通道	主要信息	下游用途
F1	64（当前 32）	高分辨率局部纹理、小病灶	U_B、mask detail
F2	128（当前 64）	局部结构 / relation evidence	A/U_B；E 的 local feature
F3	256（当前 128）	解剖区域与事件语义	A/U_B
F4	512（当前 256）	器官与全局采集质量	A、S、U_Q

当前代码使用 MONAI SwinTransformer，stem=(2,4,4)、window=(4,8,8)、相对位置偏置；完整方案计划更宽 backbone + physical 3D RoPE + M_valid propagation。必须通过消融证明 physical PE 的价值，不能只因设计直觉就称其 novelty。

5. 结构化语义层：先构造 Entity / Event，再谈 Relation

这一层的关键思想是：不要直接从 F4 做一个“病灶属于哪里”的分类头，而是先显式形成 anatomy entity A_i 与 abnormality event U_j 。只有这样，关系才能拥有稳定的端点、空间支撑和可解释的 pair representation。

5.1 Anatomy Decoder A：固定身份槽

```
Q_A = {q_i^A}; query i 永久对应 ontology 中的 anatomy i
A_i = Decoder_A(q_i^A, F2:F4)
Outputs: mask_i, presence_i, embedding A_i
```

当前膝侧 K=6: patellar cartilage、femoral cartilage、medial/lateral tibial cartilage、medial/lateral meniscus。query 身份固定，因此不做 Hungarian matching。完整方案把脑/膝纳入统一 ontology，并严格区分“存在、确认缺席、未知标注”。

5.2 Biological Event Decoder U_B：DETR 式异常实例

```
Q_B = {q_j^B}; U_j = Decoder_B(q_j^B, F1:F3)
Outputs: class_j + 3D box_j + embedding U_j
Hungarian: -P(class) + 5*L1 - 2*GIoU
```

当前 M=8、d=128，只做 meniscal tear / cartilage lesion / no-object。正式方案默认 M≈20、d≈256，并跨视图与同一参考 instance 做匹配，不能假设“query 编号相同 = 同一个病灶”。

5.3 Acquisition token S 与 Global degradation U_Q

分支	输入	输出	为什么独立
S	F4 pooling + metadata	sequence / field strength / orientation / fat suppression + embedding	同一结构在不同 contrast 下外观不同，R 需要条件化
U_Q	F4 global feature	motion/noise/aliasing presence + severity	退化是 acquisition state，不是带宿主的 lesion，不应与 U_B 共用 event queries

当前实现边界 A 与 U_B 已有最小实现；S、U_Q 头尚未实现。它们应在核心 relation hypothesis 通过后再扩展，避免在尚未验证必要性的系统上堆复杂度。

6. 显式 Relation R: 把“异常属于谁”变成一等公民

对每一个有效 anatomy A_i 与 abnormality U_j 构造候选 pair。关系模型不是简单用位置查表，而是同时读取 anatomy embedding、event embedding、physical geometry，以及完整方案中的 acquisition condition S 。

6.1 Pair geometry G_{ij}

```
G_ij = (Δz_mm, Δy_mm, Δx_mm, ||Δ||, IoA, [laterality, hierarchy])
```

当前实现只有 5 个 channel：三轴毫米位移、距离和 IoA，并且 geometry 计算 detach。完整方案可加入 laterality/hierarchy，但这些只是 inductive bias，不是 relation truth。

6.2 Pair token 与 Relation Transformer

```
r_ij^0 = phi[ A_i ; U_j ; g(G_ij) ; S ]
{r_ij^0} -> Transformer_R -> {r_ij}
```

当前 minimal 版本：K×M pair tokens → 2-layer、8-head self-attention，d=128。关系 self-attention 的意义是让一个 lesion 同时“看到”所有候选宿主，从全局候选结构中选择最合理的归属，而不是让每个 pair 独立做二分类。

6.3 两类 relation output

```
Pair relation: R_ij = sigmoid(h_R(r_ij))
Main host: P(H_j=i) = softmax_{i in valid anatomy + none}(h_host(r_ij))
```

输出	问题	适用
R_ij soft relation	U_j 与 A_i 是否有关系？	跨多个结构的 lesion / 多标签关系
main-host softmax	U_j 主要属于哪个结构？	主要归属、laterality、none host

6.4 当前最大的技术风险：GT geometry shortcut

必须修复 ArmBMinimal 当前把 GT anatomy mask、GT presence、Hungarian 匹配后的 GT box 输入 geometry/gating。由于 IoA 本身是 G_{ij} 的输入，模型可以学成“argmax IoA”的近似查表器。任何 host accuracy 都不能作为关系建模有效性的证据。正式评估必须改用 predicted masks / predicted boxes / predicted presence。

7. Relation Reliability E: 从“预测关系”升级到“知道何时不能信”

R 和 E 必须语义分离。R 回答“这条关系是否成立”；E 回答“当前图像是否有足够证据让我可靠判断这条关系”。因此，高 E 可以对应清晰的正关系，也可以对应清晰的负关系；低 E 不是 none，也不是 negative。

7.1 Local relation ROI

```
C_j = dilate(B_j, 8 mm)
Omega_ij = [ B_j u (C_j n M_i) ] n M_valid
F_local_ij = pool(F2, Omega_ij)
```

只使用 lesion box + 邻近 host anatomy，而不是把整个器官并入。目的是让 E 聚焦“这条关系真正依赖的局部证据”，避免大量正常体素淹没细小病灶的失真。训练时参考 ROI 固定并 stop-gradient；推理必须由当前图的 predicted mask / box 重新构造 ROI，并单独报告评分覆盖率。

7.2 v2.1 的物理 proxy

```
E*_fidelity(q) = exp( - NRMSE(X^q, X^0 ; Omega_ij) / tau_E )
E_ij = sigmoid( h_E[ r_ij ; F_local_ij ] )
```

优点：标签来自外部物理图像对，不是模型自己的 softmax；缺点：local NRMSE 仍不等于“这条关系是否可判”。一个极小关键边缘消失时总体 NRMSE 可能仍很低。

7.3 推荐的 2026-09-09 修订：E 以 relation failure probability 为主


推荐主目标 冻结 out-of-fold relation teacher，在每个 degraded view 上定义“该关系是否仍然预测正确”的 failure label；用 cross-fitting 避免同样本训练/打标签泄漏。E 的主评估在每一个退化档内做 AUROC/AURC/Brier；local NRMSE 降为辅助物理回归信号，而不是唯一真值。

```
E_ij ≈ P( relation prediction remains correct | X^q, pair i,j )
Auxiliary: regress / rank local fidelity E*_fidelity
```

这样 E 的科学语义直接对齐“when to trust the relation”，同时仍保留 raw k-space 提供的外部物理结构。

8. Controlled k-space Intervention：把“图像质量”变成可控实验变量

普通 augmentation 的问题是：它往往只是“把图像弄坏”，但没有明确保持什么真值、改变什么因子。AnatoBind 的关键是同一 patient / same lesion / same anatomy 的 paired views：biology 不变，acquisition evidence 可控变化。



8.1 核心三类 degradation

类型	当前状态	训练语义
Noise	已实现；只在 acquisition support 上加噪，按 coil 数归一	U_Q noise ↑；高证据时 R 应保持，E 随局部证据变化
Undersampling / aliasing	已实现 Poisson $\times 4/\times 8/\times 16$ + adjoint-SENSE	U_Q aliasing ↑；测试 relation robustness
Motion	尚未实现；需 multi-coil / shot-aware 物理模拟	关键 sim-to-real 通道；以后对 KMAR 真实 motion

8.2 干预学习的选择性一致性

High evidence: $R(X^q) \approx \text{stopgrad}(R(X^0))$
Low evidence: turn off deterministic relation/KL constraints; allow uncertainty ↑
Always: U_Q should respond to applied degradation

低证据时不能把原有生物关系标签改成 negative/none，因为 patient biology 没有随着噪声消失；正确做法是停止强迫模型在不可判图像上输出确定关系。

8.3 物理口径必须统一

注意 当前 clean X^0 来自数据集 target，而 degraded 图来自 adjoint-SENSE；如果两条 reconstruction chain 的强度尺度/重建偏差不同， E^* 会把“重建口径差”误当作 degradation evidence。正式 paired training 前必须统一或校准 reference reconstruction。

9. 训练策略与 Loss：为什么必须分阶段？

如果从第一步就把 segmentation、detection、relation、degradation、reliability 全部联合训练，任何一个分支的 shortcut 都可能掩盖另外一个分支是否真正学到了目标关系。因此完整方案采用按依赖关系开启的 staged training；而当前研发路线还应先插入“核心假设 gate”，通过后再扩大系统。

9.1 当前可执行 Arm-B loss

$$\begin{aligned} L_{\text{ArmB}} = & (L_{\text{mask}} + L_{\text{presence}}) \\ & + (L_{\text{cls}} + 5 L_l + 2 L_{\text{GIoU}}) \\ & + (L_{\text{hostCE}} + L_{\text{relBCE}}) \end{aligned}$$

它只证明训练管线可反向传播，不证明 relation superiority，因为 geometry/gating 仍使用 GT。

9.2 完整方案的目标分解

$$\begin{aligned} L_{\text{sem}} &= L_A + L_S + L_{UB} + L_Q \\ L_{\text{rel}}^0 &= L_{\text{bind}}^0 + \lambda_h * L_{\text{hard}}^0 \\ L_{\text{rel}} &= L_{\text{rel}}^0 + \text{mean}_{\{q>0\}}(L_{\text{rel}}^{\{q,w\}}) \\ L_{\text{int}} &= L_{\text{cons}} + L_Q + \lambda_E * L_{\text{obs}} + \lambda_m * L_{\text{rank}} \end{aligned}$$

阶段	训练对象	主要 loss	为什么此时训练
I. SSL	backbone	$L_{\text{MIM}} + L_{\text{contrast}}$	先获得可迁移 3D MRI 表征；但不是核心 novelty
II. Structured perception	A / S / U_B / U_Q	L_{sem}	先保证 entity/event 本身可识别，不让 R 掩盖基础感知失败
III. Clean relation	R module	L_{rel}^0	在可见证据充分时先学正常 binding 与 hard negatives
IV. Intervention + E	R / E / U_Q	$\text{gated } L_{\text{rel}} + L_{\text{int}}$	同病例退化梯度上学 selective consistency 与 reliability

9.3 Evidence gating 的逻辑

- 高证据：关系 BCE、main-host CE、hard negative、clean→degraded consistency 均可以启用/加权。
- 低证据：关闭确定性 relation supervision 与 KL；可鼓励 predictive entropy 增大。
- 未知/无 E*：既不做确定性监督，也不奖励不确定；避免把缺标签当 low-evidence。
- main-host CE 是整条 event 的 categorical distribution，不能在 softmax 前对每个 class logit 分别乘不同 evidence weight。

9.4 推荐研发顺序：先 Gate，再完整四阶段



10. 完整推理流程：一张新 MRI 进来后到底发生什么？



- 1. 输入 native 3D MRI，读取 spacing、方向与可用采集 metadata；做强度归一与必要的 crop/sliding window。
- 2. 3D Swin 生成 F1-F4；F1/F2 保留局部细节，F4 提供全局 context。
- 3. A Decoder 输出每个 anatomy slot 的 mask/presence/embedding；U_B Decoder 输出每个 lesion query 的 type/box/embedding。
- 4. 只对“当前预测存在”的 anatomy × event 构造 pair；从 predicted mask/box 计算毫米几何 G_{ij}。
- 5. Relation Transformer 联合考虑所有候选 pair，输出 pair relation R_{ij} 与每个 event 的 main-host distribution。
- 6. 用当前预测 box + nearby host anatomy 构造 Omega_{ij}，从 F2 池化 local evidence，E 头输出 relation reliability。
- 7. 最终不仅返回“检测到了什么”，而是返回结构化结果：{A, S, U_B, U_Q, R, E} + validity/coverage flags。

10.1 一个具体例子

病例示例 一张膝 MRI 中，U₃ 被识别为 meniscal tear。A₅/A₆ 分别是 medial/lateral meniscus。relation module 同时看到 U₃ embedding、A₅/A₆ embedding、毫米距离和 IoA；最终 main host 选择 A₅。若 severe undersampling 使 box 偏移，但局部 meniscus morphology 仍支持 medial host，relation model 可能保持正确；若关键边缘已经不可见，E 应下降而不是强行维持高置信度。

10.2 最终输出的临床可解释接口

输出	例子	临床意义
U_B	meniscal tear, box	“发现了什么异常”
R / main host	tear → medial meniscus	“异常属于哪里”
E	0.82 / reliable	“当前图像是否足以支持这个归属”
U_Q	aliasing high	“当前图像受什么采集退化影响”

11. 实验设计：怎样证明核心方法真的必要？

论文最重要的不是“模型比 baseline 高多少”，而是每个实验都对应一个可证伪命题。尤其在 09-09 审计后，seg-then-lookup 必须是 class-aware 强基线，而不是不看 lesion type 的稻草人。

11.1 公平主对照：同上游预测、只比较 binding 机制

Arm	Binding mechanism	目的
B0	Class-aware seg-then-lookup: class restrict candidates + IoA + nearest fallback	最强几何查表 baseline
B1	Pair MLP: [A_i,U_j,G_ij] 独立打分	检验是否只是 pair feature 足够
B2	Relation Transformer, geometry=0	检验 relation context 本身，不依赖几何 shortcut
B3	Full relation Transformer + predicted geometry	目标模型
B0-naive	不看 class 的 argmax IoA	只作为说明稻草人差距，不作主结论

11.2 推荐的新 Gate 设计

Gate	要回答的问题	通过标准的建议口径
G1 Predicted geometry	模型脱离 GT geometry 后是否仍可正常运行？	全 pipeline 计入漏检；与 teacher-forced 结果差距可解释
G2 Degradation failure	退化是否确实让 geometry lookup 失效？	按退化档报告 detection miss vs binding error；B0 曲线显著下降
G3 Relation benefit	在相同 predicted A/U_B 下，B3 是否优于 B0/B1/B2？	比较 degradation-response curve / paired errors，而不是 clean +10pp
G4 Reliability E	E 是否识别“即将绑错”的关系？	每个退化档内优于 softmax、entropy、IQA、ConfidNet 类 baseline：AUROC/AURC/Brier

11.3 五类主实验

8. Clean → degradation gradient: 观察 B0/B1/B2/B3 的 ABA 随 noise/undersampling/motion 的下降曲线。
9. Intervention vs ordinary augmentation: 两组见相同 corrupted images, 只有 AnatoBind 使用 paired relation consistency + E/U_Q 目标, 证明“配对目标”而不是“看过坏图”带来收益。
10. Held-out combination: 训练中各因子单独出现, 但保留某个 anatomy × abnormality × degradation 组合作为未见组合。
11. Sim-to-real: SKM-TEA raw motion simulation 训练 → KMAR 真实 motion 测试; 真实数据永不回流训练。
12. Reliability generalization: E 只在核心三类退化训练, 在 held-out artifact 上测试 failure prediction 是否仍校准。

12. 指标与统计：主表不能只报 Dice

指标	定义/作用	必须避免的误用
ABA - anatomy-abnormality binding accuracy	event main host 是否正确；主口径组织族级	不能只在成功检测的 lesion 子集上算而忽略漏检
Relation mAP / F1	多标签 pair relation 的整体表现	不能让 none/unknown/low-E 混为一类
RIC	干预后该变的 U_Q/E 变、不该变的 biology relation 保持	不能把 invariant 简化为所有输出都不变
AUROC / AURC	E 对 relation failure 的 discrimination / selective risk	必须在每个退化档内评估，避免 E 只学 nominal corruption level
Brier / ECE	E 的概率校准	先明确 E 的目标事件，再谈 calibration
Coverage	可评分 relation 占比、事件 recall、空 ROI / unknown 数	不能把无评分直接写 E=0

12.1 为什么 clean 96.8% 不是坏消息

它说明“located_in 在 geometry 完整时接近确定性”是任务结构事实，而不是模型失败。反过来，这使实验问题更清楚：真正有价值的是当 segmentation/detection geometry 因 acquisition degradation 发生错误时，relation representation 能否利用上下文与局部视觉证据恢复正确 binding；如果不能，那么显式 relation 模块就没有足够必要性。

12.2 统计单位

- 数据按 scan / subject 做 split，避免同一扫描的多个 lesion 或多个 corruption views 跨 train/test。
- 多个 lesion / 多个退化视图属于同一 subject，置信区间与显著性检验需考虑聚簇相关性。
- 主比较优先 paired bootstrap / McNemar；曲线比较可用 subject-level bootstrap 的 area-under-degradation-curve。

13. 当前代码已经做到了哪里？与完整方案差多少？

模块	当前状态	完整目标/缺口
Data engine	SKM-TEA 155/155 导出；noise/undersampling 可生成；脑 SynthSeg 管线存在	运动模拟、统一多器官训练输入仍需补
Backbone	缩小 3D Swin, embed_dim 32, 约 1.76M backbone params	正式宽度、physical RoPE、M_valid、SSL
A	K=6 fixed anatomy queries; mask + presence + embedding	跨器官 ontology、Mask2Former-style masked attention
U_B	M=8 DETR queries; tear/cartilage lesion + boxes	更大 event ontology、跨数据集训练
G / R	5D physical geometry + 2-layer pair Transformer + R/host heads	predicted geometry/gating; S conditioning; hard negatives
S	未实现	sequence/field/orientation/fat-sat conditioning
U_Q	未实现；但 corruption generator 部分已有	motion/noise/aliasing presence+severity head
ROI / E	未实现	predicted local ROI; failure probability + fidelity auxiliary
Training	300-step fold0 smoke run; loss 能下降	完整 staged training / fair baseline / degradation experiments

现有数字的证据边界 fold-0 smoke host accuracy 使用 GT masks / GT presence / matched GT boxes，属于 NOT_EVIDENCE；它只证明代码“能训练”，不能证明 relation binding、泛化或 reliability。

13.1 目前最值得保留的设计

- relation truth 不由 overlap 定义；IoA 只作为输入特征。
- A fixed identity queries 与 U_B DETR event queries 的语义分离。
- U_Q 不产生 R_Q；biology 与 acquisition degradation 分支分离。
- E 与 R 语义分离，且 local ROI 与 evidence supervision 使用同一物理支撑区域。

13.2 当前最需要修改的设计

- 三处 teacher forcing: GT masks / matched GT boxes / GT presence → predicted quantities。
- 主 baseline 升级为 class-aware lookup，而不是 naive argmax IoA。
- M1 的 clean +10pp gate 废弃/重定义为 degradation curve + reliability gates。
- E 从 “NRMSE proxy score” 升级为 relation failure probability 主目标；NRMSE 保留辅助。

14. 关键失败模式与风险控制

风险	为什么严重	控制方式
Geometry shortcut	R 可能只是学习 IoA/nearest lookup	predicted geometry + B0/B1/B2/B3; geo=0 消融
E 只学 corruption level	高噪=低 E 的捷径不等于 relation failure	同退化档内评估; cross-fitted failure labels; held-out artifacts
Reference ROI optimistic	GT/clean ROI 会高估 E	主评估只用 current-image predicted ROI; 单报 coverage
Reconstruction mismatch	X0 target vs Xq adjoint-SENSE 造成伪 evidence	统一/校准 reconstruction chain
Dataset identity leakage	A 可能学 “PDGM/fastMRI 样式” 而非 anatomy	domain probe; cross-dataset anatomy performance
Ontology / missing labels	缺标不等于 anatomy absent	present / confirmed absent / unknown 三态
Motion simulation 不物理	“k-space intervention” 会被审稿人质疑	multi-coil shot-aware simulation; 真实 KMAR sim-to-real
Scope creep	S/U_Q/brain/SSL 同时做会掩盖核心问题	先 core gates, 再扩展完整系统

15. Novelty 定位：论文真正应该声称什么？

AnatoBind 不应把 3D Swin、DETR query、multi-task head 或 MRI pretraining 当核心新颖性；这些都有成熟近邻。新颖性必须落在“关系级 + 物理干预 + 可靠性”这个组合，并用强 baseline 实验兑现。

候选贡献	强度判断	需要的关键证据
3D Swin / variable-size MRI encoder	弱；基础设施	只做必要消融，不作主 claim
Explicit anatomy/event pair relation	中等；一般 relation Transformer 已有近邻	公平 class-aware lookup / pair MLP / no-geo 对照
Relation-level reliability E	强潜力	失效预测与 calibration 显著优于 softmax/entropy/IQA/learned failure
Evidence-gated paired k-space learning	最强潜力	相同 corrupted data 下优于普通 augmentation；真实 degradation 验证
Robust binding when predicted geometry fails	强潜力	退化曲线中 relation model 比 lookup 更稳健，并计入漏检
Anatomy×abnormality×degradation composition	中-强，取决于实验	held-out combinations 设计和跨协议/真实外测

建议主 claim Evidence-aware anatomy-abnormality relation learning for 3D MRI: explicit entity-event binding is trained and stress-tested under controlled acquisition degradations, with a relation-specific reliability estimate that predicts when the binding can no longer be trusted.


近邻工作应在论文中主动承认：Swin UNETR / MRI representation learning (backbone/SSL)、SGTR 等 relation Transformer (relation modeling)、Chest ImaGenome / anatomy-finding grounding (anatomy-pathology relation supervision)、ConfidNet (learned failure prediction)。差异不是“别人都没做过”，而是 MRI raw k-space 允许对 relation evidence 做受控物理干预，并把 reliability 定义到具体 relation edge。

16. 建议的研发路线：最短路径验证核心假设

下面顺序与“完整四阶段训练”不同：这是研发优先级，目标是尽快判断核心 scientific bet 是否成立，再决定是否投入更大的 SSL、脑侧和多分支工程。

Priority	任务	完成判据
P0	Predicted geometry: 用 predicted masks/boxes/presence 替换 GT teacher forcing	端到端 eval 不再依赖 GT；漏检计入主指标
P1	实现 class-aware B0 lookup + B1 pair MLP + B2 no-geo relation + B3 full	同一 A/U_B 上游、相同监督/评估
P2	在已实现 noise / undersampling 上跑 degradation gradient	确认 B0 geometry binding 的真实失效模式；分开 detection miss 与 binding error
P3	定义 cross-fitted relation failure labels, 训练最小 E head	每个退化档内 AUROC/AURC/Brier 超过 softmax/entropy/NRMSE/ConfidNet-like
P4	实现 multi-coil motion intervention + KMAR sim-to-real	真实 motion 外测验证主要结论
P5	再补 hard negatives、S、U_Q、brain ontology / second battlefield	只有 core gates 通过后扩展
P6	最后再做大规模 SSL / cross-organ composition	用于泛化与论文完整性，而不是挽救核心 relation 假设

16.1 预期论文逻辑



17. 最终一页：看懂 AnatoBind-MRI 到底在干什么

输入

任意尺寸 3D MRI；训练时可有 raw k-space、解剖 mask、病灶实例、采集 metadata。

第一步 - Perception

3D Swin 提取多尺度特征；A 形成固定身份 anatomy entities；U_B 形成带 3D box 的 abnormality events；S/U_Q 描述 acquisition context 与 degradation。

第二步 - Binding

对每个 anatomy × abnormality 构造 pair token，融合实体语义与毫米级 geometry，通过 Relation Transformer 输出 R_ij 与 main host。

第三步 - Reliability

在 lesion + nearby host 的局部 ROI 上读取视觉证据，E 估计“当前图像还能不能相信这条 relation”。推荐以 cross-fitted relation failure probability 为主监督，local fidelity 为辅助。

训练关键

raw k-space 上生成同一病例的 clean/degraded paired views：biology 不变、acquisition evidence 改变。高证据时 relation 应保持；低证据时允许不确定，而不是把真关系改成 none/negative。

真正要证明

不是“模型在干净图上比查表高很多”，因为公平查表已经约 96.8%；而是“当退化让 predicted geometry 失效时，显式 relation 是否更稳健，以及 E 是否准确告诉我们什么时候关系不能再信”。

最终结构化输出

T = { A, S, U_B, U_Q, R_B, E } + validity / coverage states

如果这条主链成立，项目的价值不是又一个 segmentation/detection network，而是一种更接近临床判断结构的 MRI representation：它不仅知道“看到了什么”，还知道“它属于哪里”，以及“当前证据是否足以支持这个结论”。

代码与方案对应入口

部分	主要文件
Backbone	anatobind/model/backbone.py
A / U_B decoders	anatobind/model/decoders.py
Geometry / Relation	anatobind/model/relation.py
Minimal model	anatobind/model/armb.py
Current losses	anatobind/model/losses.py
Training dataset	anatobind/train/dataset.py
SKM-TEA engine	anatobind/data_engine/skmtea.py; skmtea_recon.py
Full research spec	RESEARCH_PLAN.md v2.1 + STATUS.md / 2026-09-09 audit

文档原则：所有“已实现 / 已验证 / 计划”严格区分。当前最小训练的 host accuracy 不作为性能证据；完整技术方案中的 S、U_Q、E、motion 和跨器官训练仍需实现与实验验证。