


AnatoBind-MRI

面向 3D MRI 的解剖-异常关系建模

通俗重构版：公式、直觉与一个真实风格病例贯穿

2026-09

核心问题：模型不只要回答“看到了什么异常”，还要回答“这个异常属于哪个解剖结构”，并且在运动、噪声、欠采导致分割和定位失真时，知道什么时候还能相信这个关系，什么时候应该拒绝自动判断。



本节只记住

这份重构版不再把公式集中堆在附录，而是对每个模块都按“它要解决什么 → 怎么算 → 用同一个病例代入数字 → 为什么这样设计”四步展开。

1 先用一个病人把整件事讲明白


贯穿病例：Patient A

一位患者接受 3D 膝关节 MRI。图像矩阵示例为 $192 \times 192 \times 96$ ，体素间距为 (0.5, 0.5, 1.0) mm。模型预定义 6 个解剖结构：

编号	解剖结构	编号	解剖结构
A_1	髌骨软骨	A_4	外侧胫骨软骨
A_2	股骨软骨	A_5	内侧半月板
A_3	内侧胫骨软骨	A_6	外侧半月板

模型在该患者中检测到一个软骨缺损，我们把它记作 U_7 。真实临床语义是： U_7 位于股骨软骨 A_2 。

普通几何方法会做一件很直接的事：看病灶框和哪个解剖 mask 更重叠，或者看病灶中心离哪个结构最近。在干净图像里这往往有效；但运动后，分割边界和病灶框都会漂移，几何查表可能突然把 U_7 判到 A_3 。AnatoBind-MRI 的研究问题因此不是“能否在干净图上比几何更聪明”，而是：



直觉解释

全方案只回答四个连续问题：看到了什么对象？异常属于谁？这条关系现在是否看得清？最终“属于谁”的判断还能不能信？

2 共享 3D Encoder：先把 MRI 变成四种“观察尺度”

输入 MRI 经统一方向、强度归一化和裁剪后进入共享 3D Swin Encoder：

数学定义

$$(F_1, F_2, F_3, F_4) = E_\theta(X).$$

为了供后续 Transformer 使用，将每层投影为统一维度 d 的 token：

$$Z_l = \text{Flatten}(P_l(F_l)) \in \mathbb{R}^{N_l \times d}.$$

直觉解释

把 F_1 到 F_4 想成从“放大镜”到“鸟瞰图”： F_1 最适合看边界， F_2 看局部关系， F_3 看解剖/异常语义， F_4 看整器官和扫描上下文。不是四个独立任务，而是同一张 MRI 的四个尺度记忆库。

贯穿病例

以 $192 \times 192 \times 96$ 为输入，一个示意性特征金字塔可以是：

层	空间尺寸（示例）	通道（示例）	主要用途
F_1	$96 \times 96 \times 48$	96	精细 mask/边界
F_2	$48 \times 48 \times 24$	192	局部关系证据
F_3	$24 \times 24 \times 12$	384	解剖/病灶语义
F_4	$12 \times 12 \times 6$	768	全局器官/采集上下文

这些数字只是实现示例，不是方法必须固定的超参数。

3 解剖实体 A_i : 固定“岗位”，再读取当前患者

3.1 为什么先有 q_i^A ，而不是先有 A_i

设解剖 ontology 中共有 K 个结构，模型内部保存 K 个可学习向量：

数学定义

$$Q_A^{(0)} = [q_1^A, \dots, q_K^A]^\top \in \mathbb{R}^{K \times d}.$$

第 i 个 query 与第 i 个解剖类别永久绑定。

直觉解释

q_i^A 更像“固定岗位”而不是当前患者的组织。比如 q_2^A 永远是“股骨软骨观察员”。刚开始它只是随机向量；训练中，因为它总被要求输出股骨软骨的正确 mask，它逐渐学会在 MRI 特征中寻找“股骨软骨应该长什么样、通常在哪里”。

每一级 decoder 都做三步：query 先读 MRI (cross-attention)，query 之间再互相协调 (self-attention)，最后经 FFN 更新：

数学定义

$$\begin{aligned} Q' &= \text{LN} (Q + \text{MHA}_{\text{cross}}(Q, Z_l, Z_l)), \\ Q'' &= \text{LN} (Q' + \text{MHA}_{\text{self}}(Q', Q', Q')), \\ D(Q, Z_l) &= \text{LN} (Q'' + \text{FFN}(Q'')). \end{aligned}$$

Anatomy 分支按粗到细读取：

$$Q_A^{(1)} = D(Q_A^{(0)}, Z_4), \quad Q_A^{(2)} = D(Q_A^{(1)}, Z_3), \quad Q_A^{(3)} = D(Q_A^{(2)}, Z_2).$$

最终第 i 行就是当前患者的解剖 embedding a_i 。

贯穿病例

同一个 q_2^A 对 Patient A 和 Patient B 是同一个模型参数，但读取不同 MRI 后：

$$q_2^A + F_{4:2}(X_A) \rightarrow a_2^{(A)}, \quad q_2^A + F_{4:2}(X_B) \rightarrow a_2^{(B)},$$

通常 $a_2^{(A)} \neq a_2^{(B)}$ 。这就是“固定身份、病例实例化”。

3.2 a_i 如何变成 mask M_i 与存在概率 p_i^A

高分辨率特征 F_1 先生成 dense mask feature $\Phi(x)$ ，而 a_i 生成一个 mask embedding：

数学定义

$$\begin{aligned} \Phi &= f_{\text{mask}}(F_1), \quad m_i = W_m a_i + b_m, \\ M_i(x) &= \text{sigmoid} (m_i^\top \Phi(x) + b_M). \end{aligned}$$

同时，存在性 head 计算

$$z_i^A = w_A^\top a_i + b_A, \quad p_i^A = \text{sigmoid}(z_i^A).$$

最终

$$A_i = \{a_i, M_i, p_i^A\}.$$

贯穿病例

对 Patient A 的股骨软骨 A_2 ，模型可能输出 $p_2^A = 0.98$ ，并产生完整的 3D 概率 mask M_2 。如果是局部 FOV，只扫到了髌股区域而胫骨软骨几乎不在视野，可能得到 $p_3^A = 0.12$ 。因此 p_i^A 回答的是“这个结构是否有效出现在当前 FOV”，不是“mask 画得有多准”。

实现/审稿风险

如果训练数据中所有 anatomy 永远完整出现，那么所有 $y_i^A = 1$ ，存在性 head 最终只会学会输出 1。要保留 p_i^A ，训练必须包含真实 partial-FOV、结构缺失或受控 crop augmentation，并明确什么比例可见才算“存在”。

4 异常事件 U_j ：不是固定“名字”，而是一组匿名发现槽位

与 anatomy 不同，病灶数量和位置每个患者都不一样。因此不能规定“第 7 个 query 永远是某类病灶”。模型只设置 M 个匿名 query：

数学定义

$$Q_U^{(0)} = [q_1^U, \dots, q_M^U]^\top \in \mathbb{R}^{M \times d},$$

并读取 $F_3 \rightarrow F_2 \rightarrow F_1$ ：

$$Q_U^{(1)} = D(Q_U^{(0)}, Z_3), \quad Q_U^{(2)} = D(Q_U^{(1)}, Z_2), \quad Q_U^{(3)} = D(Q_U^{(2)}, Z_1).$$

令 $u_j = Q_U^{(3)}[j]$ 。

每个病灶 slot 输出类别、box 与存在性：

数学定义

$$\pi_j = \text{softmax}(W_c u_j + b_c), \quad p_j^U = 1 - \pi_j(\emptyset),$$

$$B_j = \text{sigmoid}(\text{MLP}_{\text{box}}(u_j)) = (c_x, c_y, c_z, w, h, d)_j.$$

因此

$$U_j = \{u_j, c_j, B_j, p_j^U\}.$$

直觉解释

可以把 50 个病灶 query 想成 50 个“空座位”。某个患者只有 2 个病灶，就只有 2 个座位被真正占用，其他 48 个被判为 no-object。座位编号没有医学身份，因此必须通过 Hungarian matching 把预测座位和真实病灶一一配对。

4.1 Hungarian matching 用一个小例子理解

Patient A 只有两个真实病灶：GT₁= 股骨软骨缺损，GT₂= 内侧半月板撕裂。假设几个候选 query 的 matching cost 如下（数值仅示意）：

预测 slot	与 GT ₁ 的 cost	与 GT ₂ 的 cost
q_7^U	0.18	1.42
q_{19}^U	1.31	0.22
q_{23}^U	0.86	0.91

匹配算法会选 $q_7^U \leftrightarrow \text{GT}_1$ 、 $q_{19}^U \leftrightarrow \text{GT}_2$ ，其余 slot 监督为 no-object。形式上：

数学定义

$$\hat{\sigma} = \arg \min_{\sigma} \sum_{n=1}^N \left[\lambda_c C_{\text{cls}} + \lambda_1 \|B_n^{\text{GT}} - B_{\sigma(n)}\|_1 + \lambda_g (1 - \text{GIoU}_{3D}) \right].$$

贯穿病例

匹配后，我们将“发现了软骨缺损的匿名 slot”称为 U_7 。这里的 7 只是当前推理中的 slot index；换一个患者， U_7 完全可能变成 no-object 或另一个病灶。

5 预测几何 G_{ij} : 告诉模型 “它们在空间上大概怎样”

现在有了解剖 A_i 和病灶 U_j , 下一步对每一对 (A_i, U_j) 计算一个小型几何描述。这里最重要的原则是: **必须使用预测的 M_i 和预测的 B_j , 而不是 GT**。

5.1 5 维几何定义

Anatomy 的软质心:

数学定义

$$c_i^A = \frac{\sum_x M_i(x) r(x)}{\sum_x M_i(x) + \epsilon},$$

其中 $r(x)$ 已按 voxel spacing 转成 mm 坐标。病灶 box 中心得到 c_j^U , 于是

$$\Delta c_{ij} = c_j^U - c_i^A = (\Delta x_{ij}, \Delta y_{ij}, \Delta z_{ij}), \quad d_{ij} = \|\Delta c_{ij}\|_2.$$

病灶框落在 anatomy mask 内的软重叠:

$$o_{ij} = \frac{\sum_x M_i(x) \mathbf{1}[x \in B_j]}{\sum_x \mathbf{1}[x \in B_j] + \epsilon}.$$

最终

$$G_{ij} = [\Delta x_{ij}, \Delta y_{ij}, \Delta z_{ij}, d_{ij}, o_{ij}].$$

贯穿病例: U_7 与两个候选宿主

在干净 MRI 中, 预测得到:

候选	Δx	Δy	Δz	d	o	直观解释
A_2 股骨软骨	1.9	1.1	1.2	2.5 mm	0.72	很近, 且病灶大部分落在该结构
A_3 内侧胫骨软骨	-1.6	-3.4	-6.0	7.1 mm	0.18	更远, 重叠也小

因此纯几何 baseline 很容易正确选 A_2 。

贯穿病例: 运动后发生什么

若运动让 M_2 的边界向上偏移、 B_7 又向下漂移, 预测重叠可能变为:

$$o_{2,7} = 0.34, \quad o_{3,7} = 0.41.$$

此时几何查表会错误偏向 A_3 。这正是后续显式关系模型要处理的 “预测几何失效”。

本节只记住

G_{ij} 只是**证据**, 不是答案。若把 GT mask/GT box 偷偷拿来算 G_{ij} , 关系模块会获得真实几何捷径, 整篇论文就无法证明 “几何失效后还能挽救”。

6 Relation token: 把“两个对象”变成“一张候选关系卡片”

除了几何，关系判断还应看 anatomy 语义 a_i 、lesion 语义 u_j 和采集条件 s 。

采集上下文可以由 F_4 与 metadata 得到：

数学定义

$$s = \text{MLP}_S([\text{GAP}(F_4); m_{\text{meta}}]).$$

几何先编码：

$$g_{ij} = \text{MLP}_G(\tilde{G}_{ij}).$$

然后拼接：

$$z_{ij} = [a_i; u_j; g_{ij}; s], \quad r_{ij}^{(0)} = \text{LN}(W_r z_{ij} + b_r).$$

直觉解释

$r_{ij}^{(0)}$ 可以理解为一张“候选关系卡片”。例如 $r_{2,7}^{(0)}$ 上同时写着：

- 这是股骨软骨 (a_2 告诉它“谁”)；
- 这是一个软骨缺损 (u_7 告诉它“什么异常”)；
- 二者距离/重叠是多少 ($G_{2,7}$)；
- 当前是何种序列、场强、方向 (s)。

从这一刻开始，模型推理的单位不再是“一个 anatomy”或“一个 lesion”，而是“这两者有没有关系”。

7 第一级 Relation Transformer: 同一个病灶的宿主必须直接竞争

对固定 lesion U_j ，把 K 张候选关系卡片放在一起：

数学定义

$$R_j^{(0)} = [r_{1j}^{(0)}, \dots, r_{Kj}^{(0)}]^\top, \quad R_j^{(1)} = T_{\text{intra}}(R_j^{(0)}).$$

贯穿病例

对 U_7 ，模型并不是独立回答 6 次“像不像宿主”，而是把所有候选放在同一组里比较：

候选宿主	运动后几何直觉	关系语义可利用的信息
A_2 股骨软骨	overlap 0.34 (受损)	lesion 类型与软骨语义高度一致，界面特征支持
A_3 内侧胫骨软骨	overlap 0.41 (误导)	空间近，但局部纹理/界面模式不完全支持
A_5 内侧半月板	overlap 0.05	lesion 语义不匹配
其他	很小	多数证据弱

Self-attention 允许 A_2 和 A_3 的候选边直接“互相看见”，因此不是 6 个彼此独立的二分类器。

8 第二级 Relation Transformer: 让不同病灶之间交换全局信息

把所有 lesion 的候选关系边展平：

数学定义

$$\mathcal{R}^{(1)} = \text{Flatten}(\{R_j^{(1)}\}_{j=1}^M), \quad \mathcal{R}^{(2)} = T_{\text{global}}(\mathcal{R}^{(1)}),$$

输出记为 r'_{ij} 。

直觉解释

如果同一患者同时有 U_7 (软骨缺损) 和 U_{19} (同侧半月板撕裂), 全局关系图可以让不同 lesion 的空间/解剖上下文发生轻量交互。这不是为了用一个病灶“证明”另一个病灶, 而是防止每个病灶都在完全隔离的局部环境中做宿主判断。

实现/审稿风险

若 $K \times M$ 很大, 完整全局 self-attention 会带来显存平方增长。可使用 top-k lesion filtering、block attention 或 sparse attention。这个工程选择不应改变核心科学假设。

9 两个关系输出: R_{ij} 和 $P(H_j = i)$ 到底有什么不同

这是方案中很容易混淆的一点。

9.1 Pair-level relation: 这条边有没有关系

数学定义

$$z_{ij}^R = w_R^\top r'_{ij} + b_R, \quad R_{ij} = \text{sigmoid}(z_{ij}^R).$$

R_{ij} 可以扩展成多种关系, 例如“位于内部”“邻近”“侵犯”等, 因此允许一个病灶同时和多个结构有关系。

9.2 Main host: 这个病灶最主要属于谁

数学定义

$$h_{ij} = w_H^\top r'_{ij} + b_H.$$

用 anatomy existence 作为 soft prior:

$$\tilde{h}_{ij} = h_{ij} + \log(p_i^A + \epsilon),$$

$$P(H_j = i) = \frac{e^{\tilde{h}_{ij}}}{\sum_{k=1}^K e^{\tilde{h}_{kj}}}.$$

最终 $\hat{H}_j = \arg \max_i P(H_j = i)$ 。

直觉解释

R_{ij} 问的是“这两者有没有某种关系”; $P(H_j = i)$ 问的是“如果必须选一个主要宿主, 谁胜出”。前者适合 sigmoid, 多条边可以同时为真; 后者必须在 anatomy 之间 softmax 竞争。

贯穿病例: 运动后关系模型的“挽救”

假设运动后几何 baseline 因 overlap 误选 A_3 。经过 relation transformer, host logits 可能变为:

$$h_{2,7} = 2.6, \quad h_{3,7} = 1.8, \quad h_{5,7} = 0.4.$$

若 $p_2^A = 0.98, p_3^A = 0.97, p_5^A = 0.94$, soft prior 几乎不改变排序, 最后得到:

$$P(H_7 = A_2) = 0.62, \quad P(H_7 = A_3) = 0.27, \quad \text{others} = 0.11.$$

于是模型把几何错误从 A_3 挽救回 A_2 。

实现/审稿风险

这项“挽救”必须与同一组上游预测 M_i/B_j 的几何 baseline 公平比较。否则如果 B3 使用更好的 upstream, 而 B0 使用更差 upstream, 就无法证明收益来自 relation mechanism。

10 边级 e_{ij} : 不是“关系概率”，而是“这条关系现在能否判清”

只输出 R_{ij} 或 host softmax 有一个风险：严重退化时，神经网络仍可能给出非常尖锐的错误概率。因此需要一个独立层级回答“当前证据够不够”。

10.1 只看全局不够，要看病灶、解剖和二者界面

定义三个区域：

数学定义

$$\Omega_j^U = B_j, \quad \Omega_i^A = \text{Dilate}(M_i, r_A), \quad \Omega_{ij}^I = \text{Dilate}(M_i, r_I) \cap \text{Dilate}(B_j, r_I).$$

对 F_2, F_3 做 masked pooling:

$$\text{Pool}(F, \Omega) = \frac{\sum_x \Omega(x) F(x)}{\sum_x \Omega(x) + \epsilon}.$$

融合病灶、anatomy 与 interface 特征得到 F_{ij}^{local} ，再预测：

$$e_{ij} = \text{sigmoid} \left(\text{MLP}_e([r'_{ij}; F_{ij}^{\text{local}}]) \right).$$

直觉解释

一个 lesion 是否属于股骨软骨，最关键的视觉证据往往不是“整条腿长什么样”，而是病灶核心、股骨软骨邻近区域以及病灶和软骨交界处是否还能被看清。 e_{ij} 就是专门对这条局部关系做“证据体检”。

10.2 “可观测性”必须有可训练定义

“看得清”没有天然 GT。为了避免把任意 confidence 重新命名为 observability，本方案把它定义成任务层面的边可判性：

数学定义

$$e_{ij} \approx P(\text{edge}(i, j) \text{ 在当前证据下可被正确判定} \mid X).$$

用 out-of-fold relation model 在从未参与训练的样本上产生：

$$y_{ij}^e = \mathbf{1}[\hat{y}_{ij}^R = y_{ij}^{R, \text{GT}}], \quad \mathcal{L}_e = \text{BCE}(e_{ij}, y_{ij}^e).$$

贯穿病例

在干净 Patient A 中， $A_2 - U_7$ 被正确判为正边，故 $y_{2,7}^e = 1$ ； $A_5 - U_7$ 被正确判为负边，也同样可以有 $y_{5,7}^e = 1$ 。因此高 e 既可能对应“清晰的正关系”，也可能对应“清晰的负关系”。严重运动后，如果 $A_2 - U_7$ 被判错，则该退化 view 上 $y_{2,7}^e = 0$ 。

实现/审稿风险

严格来说，out-of-fold correctness 仍是“模型条件下的 operational observability”，不是物理学意义的绝对可观测性：错误可能来自模型能力不足，正确也可能有偶然性。因此论文应使用“task observability / edge decision reliability”这样的表述，并用多随机种子、重复折外预测或 ensemble 稳健性分析降低标签噪声，而不要过度宣称它是客观物理可观测量。

11 决策级 E_j ：最终这个“属于谁”的结论要不要自动接受

e_{ij} 是边级的；临床系统最终需要一个 lesion-level 判断：这次宿主结论是否值得自动输出。

先取 host 分布 Top-1 和 Top-2：

数学定义

$$i_1 = \arg \max_i P(H_j = i), \quad i_2 = \arg \max_{i \neq i_1} P(H_j = i),$$

$$P_1 = P(H_j = i_1), \quad P_2 = P(H_j = i_2), \quad \Delta_j = P_1 - P_2.$$

构造可靠性特征：

$$z_j^E = [e_{i_1 j}; e_{i_2 j}; P_1; P_2; \Delta_j; p_j^U; p_{i_1}^A; F_{i_1 j}^{\text{local}}; F_{i_2 j}^{\text{local}}],$$

$$E_j = \text{sigmoid}(\text{MLP}_E(z_j^E)).$$

严格语义是

$$E_j \approx P(\hat{H}_j = H_j^{\text{GT}} | X).$$

贯穿病例：同一个 U_7 在三个退化等级

情况	P_1	P_2	Top-1 边 e	E_7	系统行为
Clean	0.79	0.11	0.93	0.95	接受 A_2
Moderate motion	0.62	0.27	0.72	0.78	若 $\tau_E = 0.70$ ，仍接受 A_2
Severe motion	0.42	0.39	0.28	0.31	拒绝自动宿主判断

注意 severe motion 时 $\arg \max$ 仍然会硬给出一个宿主，但 $P_1 - P_2 = 0.03$ 且局部边证据很差，因此 E_7 应显著下降。

11.1 为什么 E_j 也需要 cross-fitting

若直接用模型训练集上的正误训练 reliability head，会高估可靠性。因此将数据分为 5 折，第 k 次只用 $D \setminus D_k$ 训练 relation model，再在完全未见的 D_k 上产生：

数学定义

$$y_j^E = \mathbf{1}[\hat{H}_j^{(-k)} = H_j^{\text{GT}}], \quad \mathcal{L}_E = \text{BCE}(E_j, y_j^E).$$

选择阈值 τ_E 时不只看 AUROC，还应看 risk-coverage curve：例如要求“自动接受的病例中宿主错误率 $< 5\%$ ”，再反推可接受 coverage。

12 为什么需要受控 k-space 退化：同一个病人，只改变证据

可靠性学习的理想训练对是：患者、病灶、真实宿主都不变，只让采集证据逐渐变差。原始 k-space 提供了这种干预条件。

数学定义

Clean:

$$K_c^0 = \mathcal{F}(S_c X), \quad X^0 = \mathcal{R}(K_c^0).$$

Noise:

$$K_c^\phi = K_c^0 + n, \quad n \sim \mathcal{CN}(0, \sigma^2 I).$$

Undersampling:

$$K_c^\phi = M_\Omega \odot K_c^0.$$

Motion (按 phase-encoding segment):

$$K^\phi(k) = \mathcal{F}[\mathcal{T}_{\theta_t}(X)](k), \quad k \in \Omega_t.$$

退化图仍用同一个重建算子:

$$X^\phi = \mathcal{R}(K^\phi).$$

直觉解释

这相当于对 Patient A 做“受控实验”：真实的 $U_7 \rightarrow A_2$ 关系没有改变，只是从 clean、mild motion、moderate motion 到 severe motion，MRI 证据越来越差。这样才能观察“几何什么时候开始错、relation model 能救多久、最终 reliability 何时应该拒绝”。

12.1 一致性不是所有退化都强制相同

Clean 与 degraded 的 host 分布记为 P_j^0, P_j^ϕ 。用独立物理证据构造 gate:

数学定义

$$d_j^\phi = \frac{\|W_j \odot (X^\phi - X^0)\|_2}{\|W_j \odot X^0\|_2 + \epsilon}, \quad \gamma_j^\phi = \text{stopgrad} \left[\exp \left(-\frac{d_j^\phi}{\tau} \right) \right],$$

$$\mathcal{L}_{\text{cons}} = \sum_j \gamma_j^\phi D_{JS}(P_j^0 \| P_j^\phi).$$

轻度退化时 $\gamma \approx 1$ ，要求关系稳定；严重退化时 $\gamma \rightarrow 0$ ，允许模型表达“不确定”。gate 不能直接用当前预测的 e/E ，否则模型可能通过故意把 reliability 降低来逃避 consistency loss。

13 训练并不是“一锅端”：按依赖关系分阶段更可信

阶段	主要训练对象	模型此时真正学什么	关键检查
Stage 1	Encoder	稳定的 3D MRI 多尺度表示	表征/预训练是否稳定
Stage 2	Anatomy + lesion	A_i 与 U_j 能否先被正确识别	Dice、lesion AP、box error
Stage 3	Relation	只用预测 M_i/B_j 构造 G_{ij} ，学习关系	与几何 baseline 公平比较
Stage 4	Degradation + e/E	在受控证据变化下学鲁棒关系与拒绝	OOF 标签、calibration
Stage 5	Joint fine-tune	小学习率联合优化	收益是否仍来自 relation/reliability

实现/审稿风险

不要从第一天就所有分支端到端同时训，然后只看最终 host accuracy。那样一旦结果变好，很难知道收益来自更好的 segmentation、更好的 detector，还是 relation transformer 真正做了“几何失败后的挽救”。

14 所有 loss 放在一起时，每一个到底在教什么

数学定义

$$\mathcal{L} = \lambda_A \mathcal{L}_A + \lambda_U \mathcal{L}_U + \lambda_S \mathcal{L}_S + \lambda_Q \mathcal{L}_{U^Q} + \lambda_R \mathcal{L}_R + \lambda_H \mathcal{L}_H + \lambda_C \mathcal{L}_{\text{cons}} + \lambda_e \mathcal{L}_e + \lambda_E \mathcal{L}_E.$$

Loss	通俗解释
$\mathcal{L}_A$	教固定 anatomy query 找到正确结构并画出 mask，同时判断是否出现在 FOV
$\mathcal{L}_U$	教匿名 lesion query 找到病灶、分类型、定位 3D box
$\mathcal{L}_R$	教 pair-level 边是否存在预定义关系
$\mathcal{L}_H$	教一个 lesion 的主要宿主在 K 个 anatomy 中竞争
$\mathcal{L}_{\text{cons}}$	轻度退化时，真实关系不应因为证据小变化就乱跳
$\mathcal{L}_e$	教模型识别“这条边当前还能不能可靠判断”
$\mathcal{L}_E$	教最终系统判断“这次宿主结论要不要自动接受”

本节只记住

总 loss 不是“越多越好”。任何没有对应标签或明确 operational target 的项都不应为了公式完整而硬加。尤其 S/U^Q 若数据集没有可靠标签，可以阶段性关闭，而不是伪造监督。

15 一个病例从输入到最终结论：完整数字化 walkthrough

现在把 Patient A 的 U_7 从头走一遍。

Step 1: Encoder

输入 $X \in \mathbb{R}^{1 \times 96 \times 192 \times 192}$, spacing (1.0, 0.5, 0.5) mm, 得到 $F_1 : F_4$ 。

Step 2: Anatomy branch

固定 q_2^A 代表股骨软骨, 解码后输出:

$$p_2^A = 0.98, \quad M_2 = \text{股骨软骨 3D 概率 mask}, \quad a_2 \in \mathbb{R}^{256}.$$

q_3^A 代表内侧胫骨软骨, 输出 $p_3^A = 0.97$ 。

Step 3: Lesion branch

匿名 q_7^U 经 Hungarian matching 对应到软骨缺损:

$$p_7^U = 0.96, \quad c_7 = \text{cartilage defect}, \quad B_7 = (c_x, c_y, c_z, w, h, d).$$

Step 4: 运动后预测几何出现冲突

$$G_{2,7} : d = 4.8 \text{ mm}, o = 0.34, \quad G_{3,7} : d = 4.1 \text{ mm}, o = 0.41.$$

纯几何倾向 A_3 , 即发生 geometry-induced binding error。

Step 5: 构造 6 条 candidate relation tokens

$$r_{i,7}^{(0)} = \text{LN}(W_r[a_i; u_7; g(G_{i,7}); s] + b_r), \quad i = 1, \dots, 6.$$

Intra-lesion transformer 让 6 个宿主直接竞争, global transformer 再加入其他 lesion 上下文。

Step 6: Relation 输出

$$P(H_7 = A_2) = 0.62, \quad P(H_7 = A_3) = 0.27, \quad \text{others} = 0.11.$$

关系模型成功把宿主从错误几何 A_3 挽救回 A_2 。

Step 7: 检查这条边到底还能不能看清

局部病灶、股骨软骨邻域和界面特征给出:

$$e_{2,7} = 0.72, \quad e_{3,7} = 0.58.$$

说明虽然存在运动, 但对 top-1 边仍有一定判别证据。

Step 8: 最终可靠性

$$P_1 = 0.62, \quad P_2 = 0.27, \quad \Delta = 0.35, \quad p_7^U = 0.96, \quad p_2^A = 0.98.$$

Reliability head 得到

$$E_7 = 0.78.$$

若验证集确定 $\tau_E = 0.70$, 系统输出:

接受: U_7 的主要宿主为 A_2 (股骨软骨), $E_7 = 0.78$ 。

如果同一病例进一步加重运动, 变为 $P_1 = 0.42, P_2 = 0.39, e_{2,7} = 0.28$, 并得到 $E_7 = 0.31$, 系统则应输出:

拒绝: 证据不足, 不自动给出宿主结论。

16 实验设计必须按“失败 → 挽救 → 拒绝”三步证明

这部分决定论文的科学主张是否站得住。

16.1 第一步: 先证明几何真的会失败

随着 clean → mild → moderate → severe degradation, 至少画出以下曲线:

- Anatomy Dice / boundary error;
- Lesion detection AP / center error / box IoU;
- 预测 G_{ij} 的误差;
- 几何 baseline 的 host accuracy。

若 severe degradation 下几何 baseline 几乎不降, 那么“几何失败后的 relation rescue”就没有充分动机。

16.2 第二步: 证明关系模型确实挽救了一部分失败

所有方法共享同一上游 A/U 预测:

Baseline	定义
B0	类别感知几何查表
B1	$[a_i, u_j, G_{ij}]$ 的独立 MLP, 不做候选竞争
B2	Relation Transformer, 但去掉 G_{ij} , 测试是否纯语义就够
B3	完整 AnatoBind-MRI: 语义 + 预测几何 + 两级关系推理

理想结果不是 clean 上 B3 大幅碾压 B0, 而是 clean 时接近, 退化加重后 B3 下降更慢。

16.3 第三步: 证明 e/E 能识别“已经救不回来”的样本

需要报告: AUROC、AURC、Brier、ECE、risk-coverage; 并在每个退化等级内单独评估, 避免 reliability 只学到“运动越大分数越低”。

贯穿病例

核心子集应专门选“clean 时几何正确、degraded 时几何错误”的病例。如果 B3 能把其中一部分从错误宿主恢复, 而 E 又能把剩余无法恢复的病例拒绝, 这才直接回答本研究的核心问题。

17 端到端错误不能混成一个 accuracy

对每个真实 lesion，至少区分：

状态	含义
病灶漏检	Detection failure；关系模型根本没有机会判断
病灶检出但宿主错误	Binding failure；这是 relation 的核心失败类型
宿主正确但 $E < \tau$	正确但主动拒绝；牺牲 coverage 换低 risk
宿主正确且 $E \geq \tau$	高可靠自动决策

不能只在“成功检出的病灶子集”报告 host accuracy 而忽略漏检，否则会高估真实系统表现。


18 当前方案最容易被 reviewer 质疑的 8 个点

- R1. GT leakage:** 正式 relation 输入是否任何地方使用了 GT mask、GT box、GT existence? 只允许用于监督与 oracle 分析。
- R2. p_i^A 可学习性:** 是否真的有 anatomy-absent / partial-FOV 负样本? 如果没有, 存在性 head 没有信息量。
- R3. e_{ij} 的定义:** 它是绝对“可观测性”还是 OOF task-correctness? 建议明确称为 operational task observability, 并分析标签噪声。
- R4. e 与 E 是否重复:** e 是边级可判性, E 是最终 host 决策正确概率; 需要 ablation 证明两层都有增益。
- R5. relation rescue 是否公平:** B0-B3 必须共享同一上游预测; 否则不能归因于 relation mechanism。
- R6. 退化是否改变了生物真值:** 运动/噪声/欠采只能改证据, clean/degraded 必须用同一重建口径。
- R7. global transformer 是否真的必要:** 若去掉第二级性能不变, 应简化模型; 不要为了“多智能”而保留无贡献模块。
- R8. 跨器官泛化:** 膝关节验证后, 是否能在脑/心脏等第二器官复现“几何失败—关系挽救—可靠拒绝”链条, 而不是只迁移网络结构。

本节只记住

这 8 个问题比再加一个模块更重要。只要其中第 1、3、5 点没有回答清楚, 最终 host accuracy 再高也很难构成强科学证据。


19 最短可执行研发路线



只有当前四个门槛都通过后, 再扩展运动模拟精度、 S/U^Q 、第二器官和大规模预训练。

20 最终版方法定义：一张新 MRI 进入系统后发生什么

1. **编码**: $X \rightarrow F_1 : F_4$ 。
2. **解剖实体**: 固定 identity query 得到 $A_i = \{a_i, M_i, p_i^A\}$ 。
3. **异常事件**: 匿名 lesion query 得到 $U_j = \{u_j, c_j, B_j, p_j^U\}$ 。
4. **预测几何**: 用预测 M_i 、预测 B_j 和真实 spacing 得到 G_{ij} 。
5. **关系卡片**: $[a_i, u_j, G_{ij}, S] \rightarrow r_{ij}^{(0)}$ 。
6. **候选竞争**: intra-lesion transformer 比较同一个 lesion 的所有宿主。
7. **全局关系图**: global transformer 轻量交换不同 lesion 的上下文。
8. **关系输出**: 得到 pair-level R_{ij} 与 main-host $P(H_j = i)$ 。
9. **边级证据体检**: 从病灶、anatomy 和 interface 局部特征得到 e_{ij} 。
10. **最终可靠性**: Top-1/Top-2、margin、 e 、 p^U 、 p^A 等得到 E_j ；若 $E_j < \tau_E$ ，则拒绝自动判断。



一句话闭环: 固定身份 query 把 MRI 变成“谁是解剖”，匿名 query 把 MRI 变成“发生了什么异常”，预测几何和语义把二者组成显式关系边；当几何因采集退化开始失效时，relation transformer 尝试利用剩余语义和局部证据挽救绑定，而 e_{ij} 与 E_j 负责判断这次挽救是否仍值得相信。

与上一版相比，本重构版真正改变了什么

- 不再把“解释”和“公式”拆成两套文档，而是每个模块同时给出直觉、公式和数字例子；
- 用 Patient A / lesion U_7 从输入一直贯穿到最终 Accept/Reject，保证每个变量都有具体指代；
- 明确展示 clean 与 motion 下几何查表如何从正确变错误，以及 relation model 如何挽救；
- 把 e_{ij} 的局限写清楚：它是 operational task observability，而不是天然存在的物理真值；
- 把 reviewer 最可能攻击的 GT leakage、 p_i^A 退化、OOF 标签、baseline 公平性放入正式方法边界，而不是留在实现备注里。